ANALISIS POLA PEMBELIAN PRODUK PADA DATASET ONLINE RETAIL MENGGUNAKAN ASSOCIATION RULE DENGAN ALGORITMA FP-GROWTH

Dinnetza Araafya Yudetti – 5054251018

1. Pendahuluan

Data transaksi penjualan dapat digunakan untuk mengetahui pola pembelian konsumen dan hubungan antarproduk yang sering dibeli secara bersamaan. Salah satu metode data mining yang dapat digunakan untuk menganalisis hubungan tersebut adalah Association Rule, yaitu metode untuk menemukan aturan keterkaitan antaritem berdasarkan riwayat transaksi. Pada praktikum ini, analisis dilakukan menggunakan dataset Online Retail yang berisi transaksi penjualan sebuah toko ritel online di Inggris selama periode Desember 2010 hingga Desember 2011. Dataset tersebut diolah menggunakan algoritma FP-Growth untuk menemukan kombinasi produk yang sering muncul dalam transaksi. Aturan asosiasi yang dihasilkan kemudian dievaluasi menggunakan tiga metrik, yaitu support, confidence, dan lift. Melalui analisis ini, pola pembelian konsumen dapat diidentifikasi dan dimanfaatkan sebagai dasar pertimbangan dalam menentukan strategi pemasaran, rekomendasi produk, maupun penempatan produk yang saling berkaitan.

2. Eksplorasi dan Pembersihan Data

2.1 Eksplorasi Dataset

Dataset yang digunakan pada praktikum ini adalah Online Retail yang berasal dari UCI Machine Learning Repository. Dataset tersebut memiliki 541.909 baris dan 8 kolom yang mencakup informasi transaksi penjualan, seperti nomor invoice, kode produk, deskripsi produk, jumlah pembelian, tanggal transaksi, harga satuan, identitas pelanggan, dan negara asal transaksi. Eksplorasi awal dilakukan menggunakan fungsi head(), shape, dan info() untuk mengetahui struktur, ukuran, serta tipe data pada setiap atribut. Berdasarkan hasil pemeriksaan, atribut yang digunakan dalam analisis Association Rule adalah InvoiceNo, Description, dan Quantity. Ketiga atribut tersebut dipilih karena dapat digunakan untuk mengidentifikasi transaksi, mengetahui produk yang dibeli, serta memastikan jumlah pembelian memenuhi kriteria analisis.

Atribut	**Keterangan**
InvoiceNo	Nomor identitas transaksi
StockCode	Kode identitas produk
Description	Nama atau deskripsi produk
Quantity	Jumlah produk dalam transaksi
InvoiceDate	Tanggal dan waktu transaksi
UnitPrice	Harga satuan produk
CostumerID	Nomor identitas pelanggan
Country	Negara asal transaksi

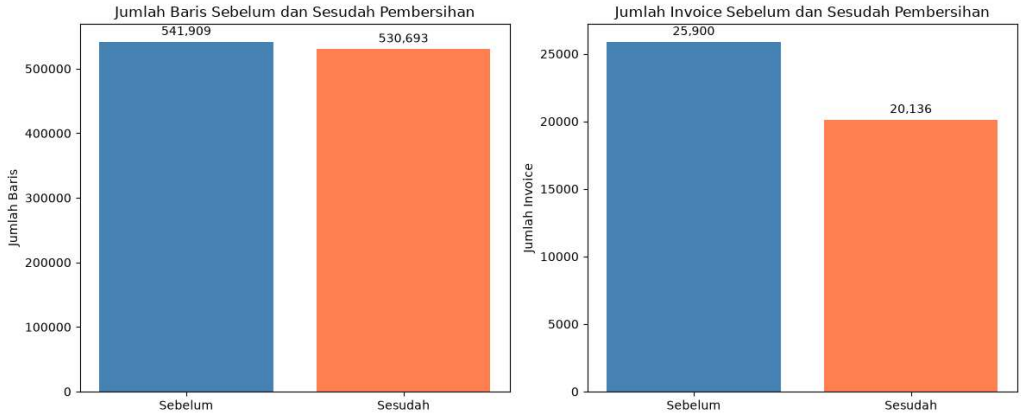
2.2 Identifikasi Data Tidak Valid

Sebelum dilakukan pemodelan, dataset diperiksa untuk mengetahui keberadaan data kosong dan transaksi yang tidak sesuai dengan kebutuhan analisis. Pemeriksaan dilakukan menggunakan fungsi isnull() untuk mengidentifikasi missing values, serta kondisi tertentu pada kolom InvoiceNo dan Quantity. Hasil pemeriksaan menunjukkan terdapat 1.454 baris dengan nilai Description kosong dan 135.080 baris dengan nilai CustomerID kosong. Selain itu, ditemukan 9.288 baris transaksi dengan nomor invoice yang diawali huruf C, yang menunjukkan transaksi pembatalan, serta 10.624 baris dengan nilai Quantity kurang dari atau sama dengan nol. Data tersebut perlu diperhatikan karena analisis Association Rule bertujuan menemukan keterkaitan produk berdasarkan transaksi pembelian yang valid. Nilai kosong pada CustomerID tidak dijadikan dasar penghapusan karena identitas pelanggan tidak digunakan dalam pembentukan transaksi.

Kondisi Data	**Jumlah Baris**
Description kosong	1.454
CostumerID kosong	135.080
InvoiceNo diawali huruf C	9.288
Quantity ≤ 0	10.624

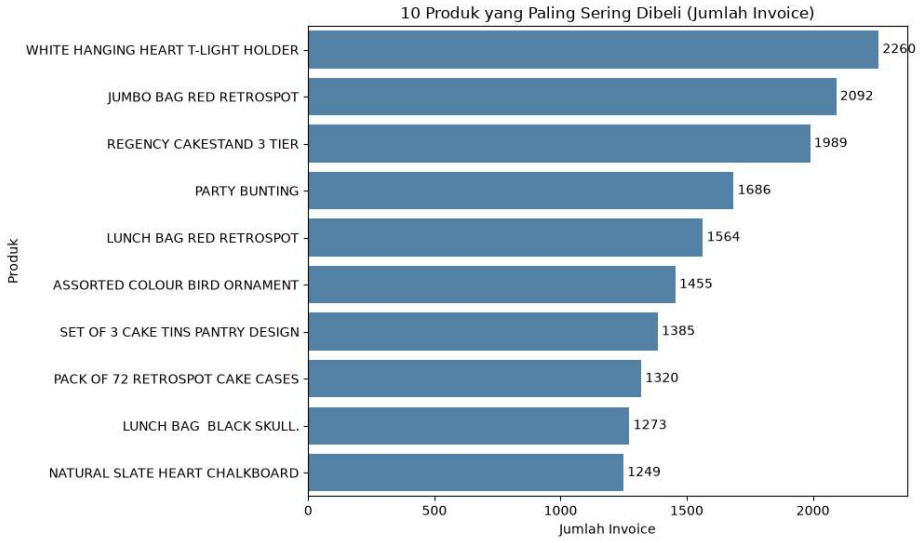
2.3 Pembersihan Data

Pembersihan data dilakukan untuk memastikan bahwa transaksi yang digunakan dalam analisis hanya mencakup pembelian produk yang valid. Tahap pertama dilakukan dengan menghapus baris yang memiliki nilai kosong pada kolom Description menggunakan fungsi dropna(). Selanjutnya, transaksi dengan nomor invoice yang diawali huruf C dihilangkan karena menunjukkan adanya pembatalan transaksi. Baris dengan nilai Quantity kurang dari atau sama dengan nol juga dihapus agar produk yang dianalisis benar-benar merepresentasikan pembelian. Setelah proses penyaringan selesai, fungsi str.strip() diterapkan pada kolom Description untuk menghilangkan spasi berlebih di awal dan akhir nama produk. Berdasarkan hasil pembersihan, jumlah baris berkurang dari 541.909 menjadi 530.693, sedangkan jumlah invoice unik berkurang dari 25.900 menjadi 20.136. Dataset hasil pembersihan juga memiliki 4.065 produk unik yang selanjutnya digunakan dalam pembentukan data transaksi.



2.4 Eksplorasi Frekuensi Pembelian Produk

Setelah pembersihan data selesai, dilakukan eksplorasi untuk mengetahui produk yang paling sering muncul dalam transaksi. Frekuensi pembelian dihitung berdasarkan jumlah invoice unik yang memuat setiap produk, bukan berdasarkan total unit barang yang terjual. Hasil eksplorasi ditampilkan dalam grafik batang yang memperlihatkan sepuluh produk dengan frekuensi transaksi tertinggi. Visualisasi tersebut digunakan untuk membandingkan tingkat kemunculan produk sekaligus memberikan gambaran awal mengenai produk yang sering dibeli pelanggan. Informasi frekuensi ini menjadi dasar pendukung dalam analisis Association Rule, meskipun produk yang sering dibeli secara individual belum tentu memiliki hubungan asosiasi yang kuat dengan produk lainnya.



3. Persiapan Data dan Penerapan Algoritma FP-Growth

3.1 Pembentukan Data Transaksi

Setelah proses pembersihan selesai, dataset diubah menjadi kumpulan transaksi berdasarkan kolom InvoiceNo. Pengelompokan dilakukan menggunakan fungsi groupby() sehingga setiap

nomor invoice merepresentasikan satu transaksi yang berisi daftar produk yang dibeli secara bersamaan. Fungsi set() digunakan untuk menghilangkan kemunculan produk yang berulang dalam invoice yang sama karena analisis Association Rule hanya mempertimbangkan keberadaan produk, bukan jumlah unit yang dibeli. Hasil pengelompokan menghasilkan 20.136 transaksi yang siap digunakan dalam proses analisis. Setiap transaksi dapat memiliki jumlah dan kombinasi produk yang berbeda sesuai dengan riwayat pembelian pelanggan.

3.2 Transformasi Data Menggunakan One-Hot Encoding

Data transaksi yang telah dikelompokkan kemudian ditransformasikan ke dalam bentuk *one-hot encoding* menggunakan TransactionEncoder dari pustaka mlxtend. Transformasi ini dilakukan agar data yang semula berupa daftar produk dapat diproses menggunakan algoritma FP-Growth. Setiap baris pada matriks merepresentasikan satu transaksi, sedangkan setiap kolom menunjukkan produk yang terdapat dalam dataset. Nilai True menunjukkan bahwa produk muncul dalam transaksi, sementara nilai False menunjukkan bahwa produk tersebut tidak dibeli. Berdasarkan hasil transformasi, diperoleh matriks basket berukuran 20.136 × 4.065 yang terdiri atas 20.136 transaksi dan 4.065 produk unik. Representasi tersebut menjadi masukan utama dalam proses pencarian frequent itemset.

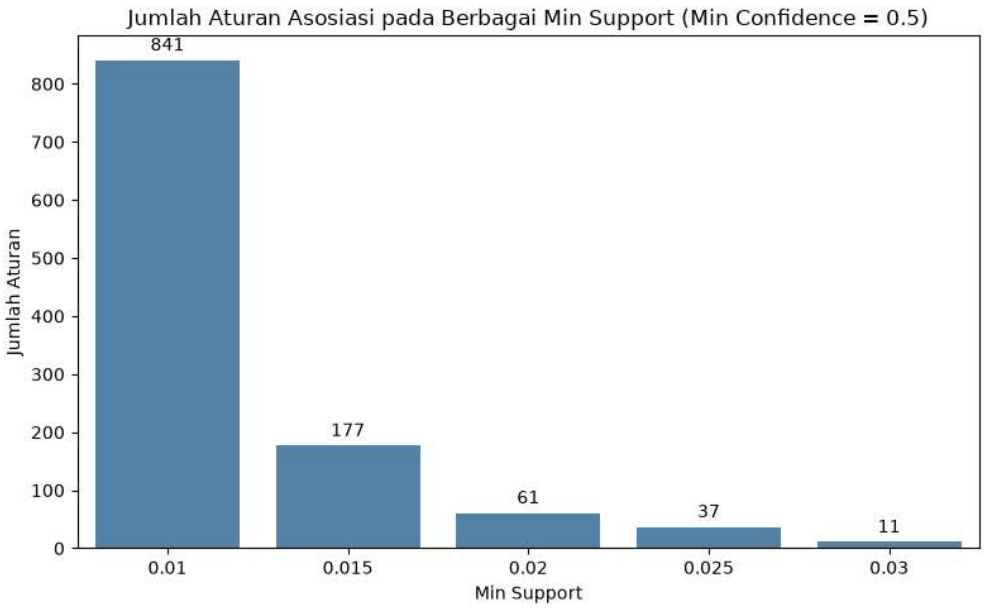
3.3 Penerapan Algoritma FP-Growth

Algoritma FP-Growth diterapkan untuk menemukan kombinasi produk yang sering muncul secara bersamaan dalam transaksi. Algoritma ini memanfaatkan struktur FP-Tree untuk merepresentasikan pola kemunculan item sehingga pencarian frequent itemset dapat dilakukan tanpa membangkitkan seluruh kandidat kombinasi seperti pada algoritma Apriori. Pada pengujian awal, digunakan nilai minimum support sebesar 0,01 dan minimum confidence sebesar 0,5 sesuai dengan ketentuan praktikum. Nilai minimum support 0,01 berarti kombinasi produk harus muncul dalam sekurang-kurangnya 1% dari keseluruhan transaksi, sedangkan minimum confidence 0,5 menunjukkan bahwa aturan yang dipertahankan harus memiliki tingkat keyakinan minimal 50%. Berdasarkan hasil pengujian, parameter awal tersebut menghasilkan 1.853 frequent itemset dan 841 aturan asosiasi. Banyaknya aturan yang ditemukan menunjukkan bahwa diperlukan pengujian parameter untuk memperoleh jumlah aturan yang lebih mudah dievaluasi dan diinterpretasikan.

3.4 Pengujian Nilai Minimum Support

Pengujian dilakukan menggunakan lima nilai minimum support, yaitu 0,01; 0,015; 0,02; 0,025; dan 0,03, dengan minimum confidence tetap sebesar 0,5. Pengujian ini bertujuan untuk mengetahui pengaruh perubahan nilai minimum support terhadap jumlah frequent itemset dan aturan asosiasi yang dihasilkan. Hasil pengujian menunjukkan bahwa peningkatan minimum support menyebabkan penurunan jumlah frequent itemset maupun aturan asosiasi. Hal ini terjadi karena semakin tinggi nilai minimum support, semakin sedikit kombinasi produk yang memenuhi batas frekuensi kemunculan dalam transaksi.

Minimum Support	Frequent Itemset	Aturan Asosiasi
0,010	1,853	841
0,015	695	177
0,020	376	61
0,025	222	37
0,030	136	11



Penggunaan minimum support 0,01 menghasilkan aturan asosiasi paling banyak, yaitu 841 aturan. Ketika nilainya ditingkatkan menjadi 0,015, jumlah aturan menurun menjadi 177, kemudian berkurang menjadi 61 aturan pada minimum support 0,02. Penurunan tersebut terus berlanjut hingga hanya menghasilkan 11 aturan pada minimum support 0,03. Perubahan jumlah aturan memperlihatkan bahwa minimum support memiliki pengaruh terhadap banyaknya pola asosiasi yang dapat ditemukan. Nilai yang terlalu rendah menghasilkan banyak aturan sehingga proses evaluasi menjadi lebih kompleks, sedangkan nilai yang terlalu tinggi berpotensi menghilangkan pola pembelian yang memiliki frekuensi relatif rendah. Berdasarkan pertimbangan tersebut, minimum support sebesar 0,02 dipilih karena menghasilkan jumlah aturan yang lebih terfokus, tetapi masih cukup beragam untuk dianalisis.

3.5 Hasil Frequent Itemset

Setelah parameter akhir ditentukan, algoritma FP-Growth dijalankan kembali menggunakan minimum support sebesar 0,02 dan minimum confidence sebesar 0,5. Hasil pemrosesan menunjukkan bahwa terdapat 376 frequent itemset yang memenuhi batas minimum support dan menghasilkan 61 aturan asosiasi. Frequent itemset merupakan kumpulan satu atau beberapa produk yang memiliki tingkat kemunculan minimum sesuai parameter yang ditentukan. Berdasarkan hasil pengurutan nilai support, produk WHITE HANGING HEART T-LIGHT

HOLDER memiliki support tertinggi sebesar 0,1122 atau sekitar 11,22% dari seluruh transaksi. Produk berikutnya adalah JUMBO BAG RED RETROSPOT dengan support sebesar 0,1039 dan REGENCY CAKESTAND 3 TIER sebesar 0,0988. Hasil tersebut menunjukkan bahwa ketiga produk memiliki frekuensi kemunculan yang relatif tinggi dalam transaksi penjualan, meskipun tingginya support suatu produk belum secara langsung menunjukkan kekuatan hubungan asosiasinya dengan produk lain.

4. Hasil dan Evaluasi Association Rule

4.1 Hasil Pembentukan Aturan Asosiasi

Setelah frequent itemset diperoleh menggunakan algoritma FP-Growth, tahap selanjutnya adalah membentuk aturan asosiasi menggunakan fungsi association_rules() dari pustaka mlxtend. Aturan dibentuk berdasarkan minimum confidence sebesar 0,5 dengan frequent itemset yang sebelumnya diperoleh menggunakan minimum support sebesar 0,02. Setiap aturan terdiri atas antecedents sebagai produk atau kombinasi produk yang menjadi kondisi awal dan consequents sebagai produk yang memiliki keterkaitan dengan kondisi tersebut. Hasil pemrosesan menghasilkan 61 aturan asosiasi yang telah memenuhi batas minimum support dan confidence. Aturan yang diperoleh kemudian diurutkan berdasarkan nilai lift tertinggi untuk mengetahui hubungan antarproduk yang paling kuat. Hasil tersebut ditampilkan dalam bentuk tabel yang memuat antecedents, consequents, support, confidence, dan lift sebagai dasar evaluasi.

4.2 Evaluasi Metrik Support, Confidence, dan Lift

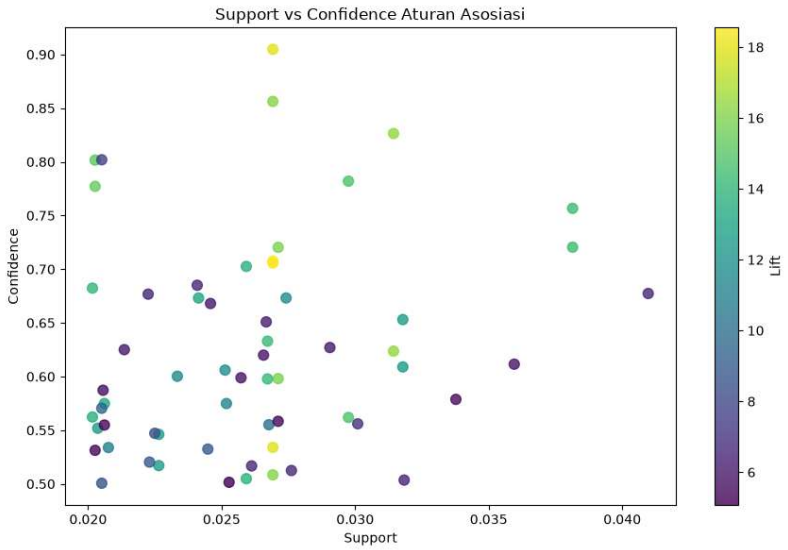
Evaluasi aturan asosiasi dilakukan menggunakan tiga metrik utama, yaitu support, confidence, dan lift. Support menunjukkan proporsi transaksi yang mengandung seluruh produk dalam suatu aturan, sedangkan confidence menunjukkan peluang kemunculan consequents ketika antecedents ditemukan dalam transaksi. Sementara itu, lift digunakan untuk mengukur seberapa kuat hubungan kedua kelompok produk dibandingkan dengan kondisi ketika pembeliannya tidak saling berkaitan. Nilai lift lebih besar dari satu menunjukkan adanya asosiasi positif antara produk yang dianalisis. Ketiga metrik tersebut digunakan secara bersamaan karena nilai confidence yang tinggi belum tentu menunjukkan hubungan produk yang kuat apabila consequents memang sering dibeli secara umum.

Statistik	Support	Confidence	Lift
Jumlah aturan	61	61	61
Rata-rata	0,0261	0,6238	10,9929
Standar deviasi	0,0049	0,0976	4,2088
Minimum	0,0202	0,5006	5,0768
Kuartil 25%	0,0223	0,5518	6,5196
Median	0,0261	0,6003	11,6853
Kuartil 75%	0,0274	0,6773	14,2926
Maksimum	0,0410	0,9048	18,5516

Nilai support dari seluruh aturan berada pada rentang 0,0202 hingga 0,0410, yang menunjukkan bahwa kombinasi produk dalam aturan ditemukan pada sekitar 2,02% hingga 4,10% dari keseluruhan transaksi. Nilai confidence memiliki rata-rata sebesar 0,6238 atau 62,38%, dengan nilai tertinggi mencapai 90,48%, sehingga terdapat aturan dengan tingkat kemunculan consequents yang relatif tinggi ketika antecedents dibeli. Sementara itu, nilai lift berada pada rentang 5,0768 hingga 18,5516 dengan rata-rata sebesar 10,9929. Seluruh aturan memiliki nilai lift lebih besar dari satu, yang menunjukkan adanya hubungan asosiasi positif antara produk-produk dalam aturan. Walaupun demikian, nilai lift yang tinggi tetap perlu dipertimbangkan bersama support karena hubungan yang kuat tidak selalu menunjukkan frekuensi pembelian yang besar.

4.3 Visualisasi Hubungan Support, Confidence, dan Lift

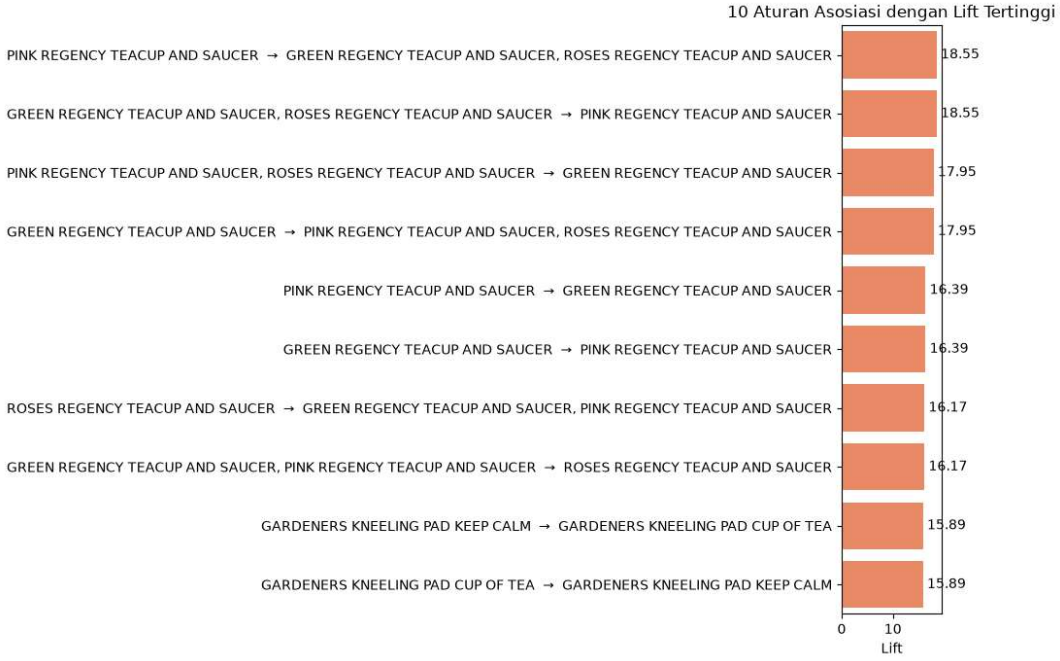
Hubungan antara ketiga metrik dievaluasi lebih lanjut menggunakan scatter plot dengan support sebagai sumbu horizontal, confidence sebagai sumbu vertikal, dan lift sebagai indikator warna. Visualisasi ini digunakan untuk mengamati sebaran aturan serta membandingkan kekuatan asosiasi berdasarkan kombinasi nilai metrik yang dihasilkan. Berdasarkan grafik, aturan asosiasi memiliki nilai support yang relatif rendah karena sebagian besar kombinasi produk hanya muncul pada sebagian kecil transaksi. Meskipun demikian, beberapa aturan memperlihatkan nilai confidence dan lift yang cukup tinggi sehingga menunjukkan adanya keterkaitan pembelian yang kuat. Perbedaan warna pada titik-titik grafik memperlihatkan bahwa aturan dengan nilai support atau confidence yang lebih besar tidak selalu mempunyai nilai lift tertinggi. Hal tersebut menunjukkan pentingnya penggunaan ketiga metrik secara bersamaan agar pemilihan aturan tidak hanya didasarkan pada frekuensi kemunculan atau tingkat keyakinan.



4.4 Perbandingan Aturan Berdasarkan Nilai Lift

Untuk mengidentifikasi aturan dengan hubungan paling kuat, dilakukan pemeringkatan berdasarkan nilai lift dari yang tertinggi hingga terendah. Sepuluh aturan dengan nilai lift tertinggi

kemudian divisualisasikan menggunakan grafik batang horizontal untuk memperlihatkan perbandingan kekuatan hubungan antarproduk. Berdasarkan hasil pemeringkatan, aturan dengan lift tertinggi mencapai 18,5516 dan melibatkan kombinasi produk PINK REGENCY TEACUP AND SAUCER, GREEN REGENCY TEACUP AND SAUCER, serta ROSES REGENCY TEACUP AND SAUCER. Nilai tersebut menunjukkan bahwa ketiga produk memiliki hubungan pembelian yang jauh lebih kuat dibandingkan dengan kondisi pembelian independen. Beberapa aturan lainnya juga melibatkan variasi produk dari seri REGENCY, yang mengindikasikan kecenderungan pelanggan membeli produk dengan jenis dan desain yang saling berkaitan. Pola tersebut dapat menjadi pertimbangan dalam penyusunan rekomendasi produk maupun strategi penawaran paket untuk meningkatkan peluang pembelian produk secara bersamaan.



5. Interpretasi Tiga Aturan Asosiasi Terbaik

5.1 Pemilihan Tiga Aturan Terbaik

Berdasarkan hasil evaluasi, tiga aturan asosiasi terbaik dipilih menggunakan nilai lift tertinggi dari 61 aturan yang dihasilkan. Pemilihan berdasarkan lift dilakukan karena metrik tersebut menunjukkan kekuatan hubungan antarproduk dibandingkan dengan kondisi ketika pembeliannya tidak saling berkaitan. Hasil pemeringkatan menunjukkan bahwa ketiga aturan terbaik melibatkan produk PINK REGENCY TEACUP AND SAUCER, GREEN REGENCY TEACUP AND SAUCER, dan ROSES REGENCY TEACUP AND SAUCER. Ketiga produk tersebut merupakan variasi dari seri perlengkapan cangkir dan tatakan yang memiliki keterkaitan dalam pola pembelian pelanggan.

Aturan	Support	Confidence	Lift
Pink → Green, Roses	0,0269	0,7076	18,5516
Green, Roses → Pink	0,0269	0,7057	18,5516
Pink, Roses → Green	0,0269	0,9048	17,9506

5.2 Interpretasi Aturan Pertama

Aturan pertama menunjukkan hubungan pembelian antara PINK REGENCY TEACUP AND SAUCER dengan kombinasi GREEN REGENCY TEACUP AND SAUCER dan ROSES REGENCY TEACUP AND SAUCER. Nilai support sebesar 0,0269 menunjukkan bahwa sekitar 2,69% dari seluruh transaksi mengandung ketiga produk tersebut secara bersamaan. Nilai confidence sebesar 0,7076 berarti sekitar 70,76% transaksi yang mengandung produk Pink juga mengandung produk Green dan Roses. Sementara itu, nilai lift sebesar 18,5516 menunjukkan bahwa kombinasi Green dan Roses muncul bersama pembelian Pink sekitar 18,55 kali lebih sering dibandingkan dengan tingkat yang diharapkan apabila pembelian kedua kelompok produk tidak saling berkaitan. Hubungan tersebut menunjukkan kecenderungan pelanggan untuk membeli beberapa variasi produk dari seri REGENCY secara bersamaan.

5.3 Interpretasi Aturan Kedua

Aturan kedua menunjukkan bahwa pembelian GREEN REGENCY TEACUP AND SAUCER dan ROSES REGENCY TEACUP AND SAUCER berkaitan dengan pembelian PINK REGENCY TEACUP AND SAUCER. Nilai support sebesar 0,0269 menunjukkan bahwa ketiga produk muncul bersamaan pada sekitar 2,69% dari keseluruhan transaksi. Nilai confidence sebesar 0,7057 mengindikasikan bahwa sekitar 70,57% transaksi yang mengandung produk Green dan Roses juga mengandung produk Pink. Nilai lift sebesar 18,5516 menunjukkan hubungan asosiasi positif yang kuat antara kedua kelompok produk tersebut. Meskipun nilai lift aturan pertama dan kedua sama, nilai confidence keduanya berbeda karena kondisi awal atau antecedents yang digunakan tidak sama. Hasil ini memperlihatkan bahwa hubungan asosiasi dapat dianalisis dari arah yang berbeda, tetapi peluang bersyarat yang dihasilkan tidak selalu memiliki nilai yang sama.

5.4 Interpretasi Aturan Ketiga

Aturan ketiga menunjukkan hubungan antara kombinasi PINK REGENCY TEACUP AND SAUCER dan ROSES REGENCY TEACUP AND SAUCER dengan GREEN REGENCY TEACUP AND SAUCER. Nilai support sebesar 0,0269 menunjukkan bahwa sekitar 2,69% dari seluruh transaksi mengandung ketiga produk secara bersamaan. Nilai confidence sebesar 0,9048 menunjukkan bahwa sekitar 90,48% transaksi yang mengandung produk Pink dan Roses juga mengandung produk Green. Nilai tersebut merupakan confidence tertinggi di antara ketiga aturan terbaik yang dianalisis. Sementara itu, nilai lift sebesar 17,9506 menunjukkan bahwa pembelian Green bersama kombinasi Pink dan Roses terjadi sekitar 17,95 kali lebih sering dibandingkan dengan tingkat yang diharapkan apabila kedua kelompok produk tidak saling berkaitan. Hasil ini

menunjukkan bahwa produk Green memiliki keterkaitan yang sangat kuat dengan kombinasi pembelian Pink dan Roses.

5.5 Implikasi Hasil Analisis terhadap Strategi Bisnis

Berdasarkan ketiga aturan terbaik, pola pembelian pelanggan menunjukkan adanya keterkaitan yang kuat antara beberapa variasi produk dari seri REGENCY TEACUP AND SAUCER. Temuan ini dapat dimanfaatkan oleh toko ritel untuk merancang strategi pemasaran yang mempertimbangkan kecenderungan pembelian produk secara bersamaan. Salah satu strategi yang dapat diterapkan adalah memberikan rekomendasi produk Green dan Roses kepada pelanggan yang memilih produk Pink, atau menawarkan paket pembelian yang mencakup ketiga variasi produk tersebut. Selain itu, informasi asosiasi dapat digunakan sebagai pertimbangan dalam menyusun promosi produk yang saling melengkapi. Namun, penerapan strategi tersebut tetap perlu mempertimbangkan tingkat permintaan dan keuntungan penjualan karena hubungan asosiasi yang kuat tidak secara langsung menunjukkan peningkatan penjualan atau hubungan sebab-akibat. Dengan demikian, hasil Association Rule dapat dijadikan dasar awal dalam pengambilan keputusan pemasaran yang lebih terarah.

6. Kesimpulan

Berdasarkan hasil praktikum Association Rule menggunakan algoritma FP-Growth pada dataset Online Retail, diperoleh kesimpulan sebagai berikut.

1. Penerapan Association Rule dapat digunakan untuk mengidentifikasi hubungan antarproduk berdasarkan pola pembelian pelanggan. Setelah proses pembersihan, jumlah data berkurang dari 541.909 menjadi 530.693 baris dengan 20.136 transaksi valid yang digunakan dalam analisis.

2. Algoritma FP-Growth berhasil menemukan 376 frequent itemset dan menghasilkan 61 aturan asosiasi menggunakan minimum support sebesar 0,02 dan minimum confidence sebesar 0,5. Pemilihan parameter tersebut menghasilkan jumlah aturan yang lebih terfokus dibandingkan pengujian awal dengan minimum support sebesar 0,01 yang menghasilkan 841 aturan.

3. Evaluasi berdasarkan support, confidence, dan lift menunjukkan adanya hubungan pembelian yang kuat antara produk PINK, GREEN, dan ROSES REGENCY TEACUP AND SAUCER. Nilai lift tertinggi mencapai 18,5516, sedangkan confidence tertinggi dari tiga aturan terbaik mencapai 90,48%. Hasil tersebut menunjukkan bahwa ketiga variasi produk memiliki kecenderungan untuk dibeli secara bersamaan dan dapat menjadi pertimbangan dalam pengembangan strategi rekomendasi produk maupun penawaran paket pembelian.