KLASIFIKASI TRANSAKSI KARTU KREDIT MENGGUNAKAN RANDOM FOREST DENGAN PENANGANAN CLASS IMBALANCE

Dinnetza Araafya Yudetti – 5054251018

1. Pendahuluan

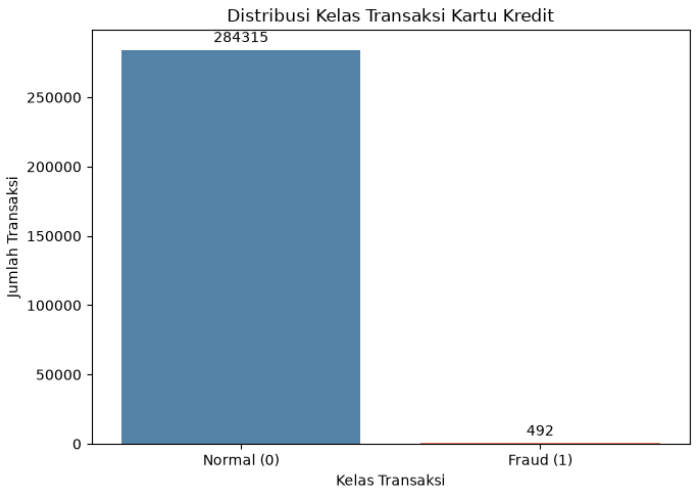
Credit Card Fraud Detection memiliki jumlah transaksi normal yang jauh lebih besar daripada transaksi fraud. Deteksi penipuan transaksi kartu kredit merupakan masalah klasifikasi yang menuntut kemampuan model dalam mengenali kejadian yang jarang terjadi. Dataset. Kondisi ini dapat membuat nilai accuracy tampak tinggi meskipun sebagian transaksi penipuan tidak terdeteksi. Oleh karena itu, penilaian model perlu melibatkan precision, recall, F1-score, ROC-AUC, dan confusion matrix.

Praktikum ini bertujuan menerapkan ensemble method Random Forest, mengidentifikasi ketidakseimbangan kelas, serta membandingkan kinerja model tanpa penanganan imbalance, dengan SMOTE, dan dengan StandardScaler sebelum SMOTE. Perbandingan dilakukan pada data uji yang sama agar pengaruh perlakuan terhadap data latih dapat diamati.

2. Dataset dan Metodologi

Dataset creditcard.csv berisi 284.807 transaksi dengan 31 kolom, yaitu 30 fitur masukan dan satu target Class. Variabel Time menyatakan selang waktu transaksi, Amount menunjukkan besaran transaksi, sedangkan V1–V28 merupakan fitur hasil transformasi. Kelas 0 menandai transaksi normal dan kelas 1 menandai fraud. Pemeriksaan awal menunjukkan seluruh kolom bertipe numerik dan tidak memiliki missing values.

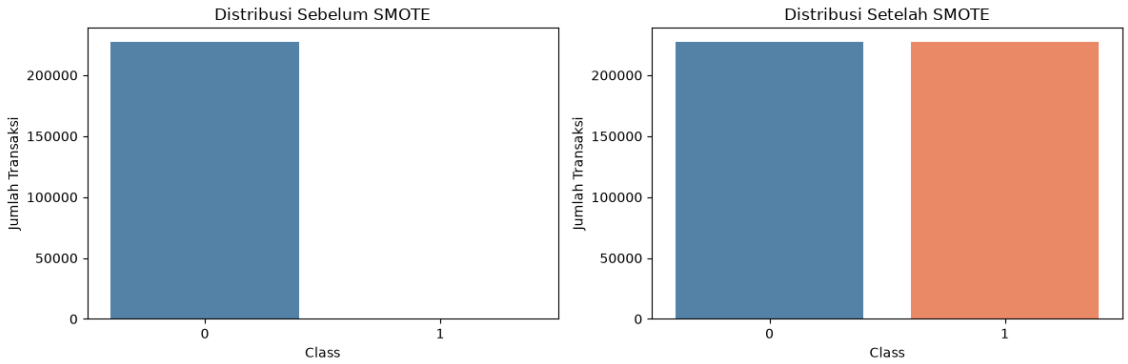
Kelas	Jumlah	Presentase
Normal (0)	284.315	99,827%
Fraud (1)	492	0,173%



Gambar 1. Distribusi kelas pada dataset awal.

Sebanyak 284.315 transaksi tergolong normal dan hanya 492 termasuk fraud. Perbedaan ini menegaskan adanya class imbalance yang sangat besar. Dataset dibagi menjadi 80% data latih (227.845 transaksi) dan 20% data uji (56.962 transaksi) menggunakan stratify=y dan random_state=42. Data latih terdiri atas 227.451 transaksi normal dan 394 fraud, sedangkan data uji terdiri atas 56.864 normal dan 98 fraud.

Tiga skenario diuji menggunakan RandomForestClassifier dengan n_estimators=100, random_state=42, dan n_jobs=-1. Skenario pertama memakai data latih asli sebagai baseline. Skenario kedua menerapkan SMOTE pada data latih tanpa scaling. Skenario ketiga menggunakan StandardScaler yang di-fit pada data latih, diikuti SMOTE pada data latih hasil scaling. Data uji hanya ditransformasikan dengan scaler yang sama dan tidak di-resampling, sehingga distribusi aslinya tetap terjaga.



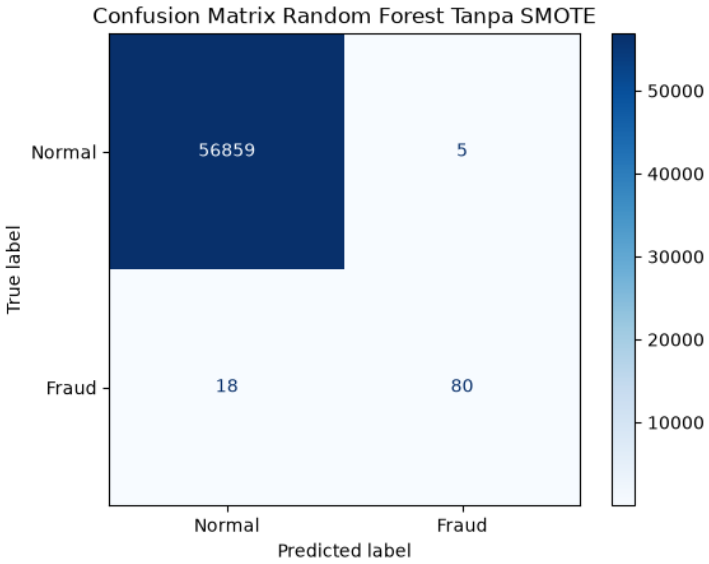
Gambar 2. Distribusi data latih sebelum dan sesudah SMOTE.

SMOTE meningkatkan jumlah sampel fraud dalam data latih dari 394 menjadi 227.451 sehingga setara dengan kelas normal. Penambahan tersebut merupakan sampel sintetis, bukan transaksi fraud baru yang teramati. Penggunaan scaling pada skenario ketiga ditujukan untuk mengurangi pengaruh perbedaan skala fitur dalam perhitungan jarak yang digunakan SMOTE.

3. Hasil dan Pembahasan

Model	Accuracy	Precision	Recall	F1-score	ROC-AUC
Baseline	0,9996	0,9412	0,8163	0,8743	0,9630
RF + SMOTE	0,9994	0,8351	0,8265	0,8308	0,9644
RF + Scaling + SMOTE	0,9995	0,8710	0,8265	0,8482	0,9685

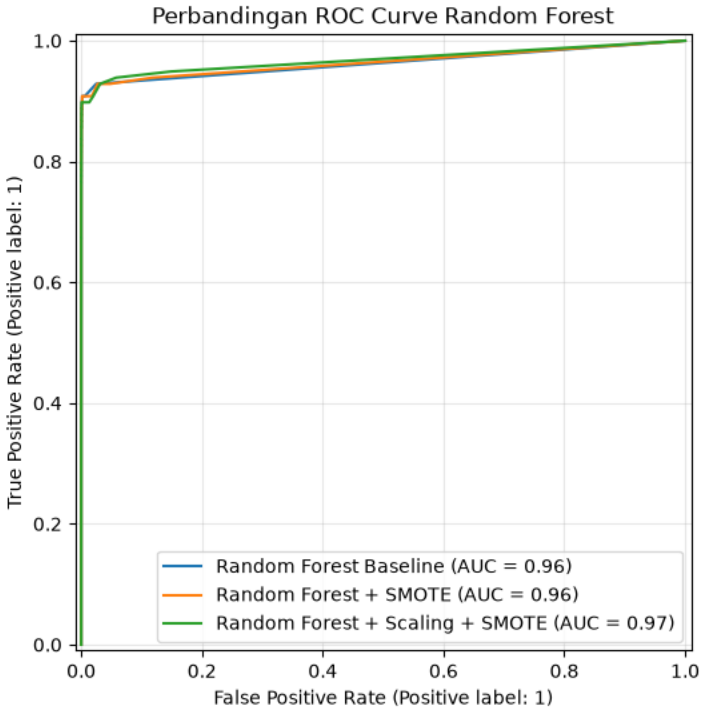
Random Forest baseline memperoleh precision 0,9412, recall 0,8163, F1-score 0,8743, dan ROC-AUC 0,9630. Confusion matrix menunjukkan 56.859 true negative, 5 false positive, 18 false negative, serta 80 true positive. Artinya, model mengenali 80 dari 98 transaksi fraud, tetapi masih melewatkan 18 transaksi penipuan. Accuracy yang sangat tinggi perlu dibaca secara hati-hati karena kelas normal mendominasi data uji.



Gambar 3. Confusion matrix Random Forest baseline.

Setelah SMOTE tanpa scaling, recall naik dari 0,8163 menjadi 0,8265. Jumlah fraud yang terdeteksi bertambah dari 80 menjadi 81, sedangkan false negative turun menjadi 17. Namun, false positive meningkat dari 5 menjadi 16 sehingga precision turun menjadi 0,8351 dan F1-score menjadi 0,8308. Hasil ini menunjukkan bahwa peningkatan deteksi fraud disertai lebih banyak kesalahan saat menandai transaksi normal.

Penambahan StandardScaler sebelum SMOTE memperbaiki precision dari 0,8351 menjadi 0,8710 dan F1-score dari 0,8308 menjadi 0,8482 dibandingkan SMOTE biasa. Recall tetap 0,8265, sedangkan ROC-AUC meningkat menjadi 0,9685, tertinggi di antara ketiga model. Dari precision 0,8710 dan 81 true positive, dapat diturunkan bahwa model ketiga menghasilkan 12 false positive; jumlah false negative tetap 17. Perbaikan ini konsisten dengan dugaan bahwa scaling membantu pemilihan tetangga pada SMOTE, tetapi eksperimen ini belum membuktikan penyebabnya secara pasti.



Gambar 4. Perbandingan ROC curve ketiga model.

Ketiga ROC curve berada dekat sudut kiri atas, yang menunjukkan kemampuan pemeringkatan transaksi fraud relatif baik. Nilai ROC-AUC tertinggi tidak otomatis menghasilkan F1-score tertinggi karena ROC-AUC menilai performa di berbagai threshold, sedangkan F1-score dihitung dari keputusan klasifikasi pada threshold yang digunakan. Berdasarkan hasil ini, baseline lebih unggul dari sisi precision dan F1-score, sedangkan Scaling + SMOTE unggul untuk ROC-AUC dan menyamai recall tertinggi. Pemilihan model sebaiknya mempertimbangkan konsekuensi transaksi fraud yang lolos dan transaksi normal yang keliru ditandai fraud.

4. Kesimpulan

Dataset Credit Card Fraud Detection memiliki distribusi kelas yang sangat tidak seimbang, yaitu 99,827% transaksi normal dan 0,173% fraud. Random Forest baseline berhasil mendeteksi 80 dari 98 fraud pada data uji dan menghasilkan F1-score tertinggi sebesar 0,8743. Penerapan SMOTE meningkatkan deteksi menjadi 81 fraud, tetapi juga meningkatkan kesalahan prediksi transaksi normal sehingga F1-score turun menjadi 0,8308. Penambahan scaling sebelum SMOTE menaikkan F1-score menjadi 0,8482 dan menghasilkan ROC-AUC tertinggi sebesar 0,9685. Dengan hasil pengujian ini, baseline merupakan pilihan terbaik berdasarkan F1-score, sementara Scaling + SMOTE memberikan kemampuan pemeringkatan terbaik berdasarkan ROC-AUC.