

LAPORAN TUGAS PRAKTIKUM DATA MINING 2

PRAPROSES DATA

Dataset House Prices - Advanced Regression Techniques

Dinnetza Araafya Yudetti - 5054251018

1. Pendahuluan


Praproses data dilakukan agar dataset siap digunakan untuk analisis atau pemodelan machine learning. Tahapan yang diterapkan meliputi pemeriksaan dan penanganan missing value, deteksi serta penanganan outlier, transformasi data melalui standardisasi dan one-hot encoding, analisis korelasi, serta reduksi dimensi menggunakan Principal Component Analysis (PCA). Proses ini bertujuan meningkatkan kualitas data sekaligus mengurangi informasi yang redundan sebelum data digunakan pada tahap analisis berikutnya.

2. Dataset

Dataset yang digunakan adalah House Prices - Advanced Regression Techniques pada file train.csv. Dataset awal memiliki 1.460 observasi dan 81 atribut yang memuat karakteristik rumah, seperti luas lahan, kualitas bangunan, tahun pembangunan, fasilitas rumah, dan harga jual (SalePrice). Pada tahap awal juga dilakukan pemeriksaan struktur data menggunakan head(), shape, dan info() untuk memahami tipe data dan kelengkapan setiap atribut.

3. Pembersihan Data

Pemeriksaan missing value menunjukkan terdapat 19 atribut yang memiliki data kosong. Lima atribut memiliki proporsi missing value lebih dari 50%, yaitu PoolQC (99,52%), MiscFeature (96,30%), Alley (93,77%), Fence (80,75%), dan MasVnrType (59,73%). Kelima atribut tersebut dihapus karena sebagian besar observasinya tidak memiliki informasi pada atribut tersebut. Setelah penghapusan, jumlah kolom berkurang dari 81 menjadi 76.




Gambar 1. Distribusi jumlah missing value sebelum pembersihan data


Missing value yang tersisa ditangani berdasarkan karakteristik atribut. Nilai kosong pada atribut kategoris fasilitas seperti fireplace, garage, dan basement diisi dengan kategori 'None' untuk merepresentasikan tidak adanya fasilitas. GarageYrBlt dan MasVnrArea diisi menggunakan median, Electrical menggunakan modus, sedangkan LotFrontage diimputasi menggunakan median berdasarkan Neighborhood. Setelah proses tersebut, total missing value menjadi 0.

4. Deteksi dan Penanganan Outlier

Outlier dideteksi menggunakan metode Interquartile Range (IQR) dan divisualisasikan melalui boxplot. Hasil deteksi menunjukkan beberapa atribut numerik memiliki nilai di luar rentang whisker. Nilai ekstrem tidak langsung dihapus karena dapat merepresentasikan kondisi rumah yang valid. Penanganan dilakukan dengan IQR capping pada LotFrontage, LotArea, GrLivArea, TotalBsmtSF, dan SalePrice sehingga pengaruh nilai ekstrem berkurang tanpa menghilangkan observasi.



Gambar 2. Boxplot atribut numerik terpilih sebelum penanganan outlier.




Gambar 3. Boxplot atribut numerik terpilih setelah IQR capping.

5. Transformasi Data

Atribut numerik, kecuali Id dan SalePrice, distandarisasi menggunakan StandardScaler agar memiliki skala yang sebanding. Standarisasi penting karena PCA sensitif terhadap perbedaan skala antarfitur. Selanjutnya, atribut kategoris diubah menjadi representasi numerik menggunakan one-hot encoding dengan `drop_first=True`. Proses encoding meningkatkan ukuran dataset dari 76 kolom menjadi 245 kolom, sementara jumlah observasi tetap 1.460.

6. Reduksi Dimensi

Analisis korelasi dilakukan pada 243 fitur setelah Id dan SalePrice dipisahkan. Pasangan fitur dengan nilai korelasi absolut lebih dari 0,90 dianggap sangat berkorelasi dan berpotensi membawa informasi redundan. Berdasarkan kriteria tersebut, 15 fitur dihapus sehingga jumlah fitur berkurang dari 243 menjadi 228 sebelum PCA dilakukan. PCA kemudian diterapkan pada 228 fitur tersebut. Jumlah principal component ditentukan berdasarkan cumulative explained variance sebesar minimal 95%. Hasilnya menunjukkan bahwa 66 principal component mampu mempertahankan 95.07% variasi informasi dari data, sehingga jumlah fitur dapat direduksi secara signifikan tanpa kehilangan sebagian besar informasi yang terkandung pada fitur awal.



Gambar 4. Cumulative explained variance PCA; batas 95% tercapai pada 66 komponen.

7. Ringkasan Hasil

Tahap	Hasil
Dataset awal	1.460 baris x 81 kolom
Kolom missing > 50%	5 Kolom dihapus
Setelah pembersihan	1.460 baris x 76 kolom, missing value = 0
Setelah one-hot encoding	1.460 baris x 245 kolom
Fitur untuk analisis	243 fitur (Id dan SalePrice dipisahkan)
Setelah reduksi korelasi	228 fitur
Setelah PCA	66 principal component, explained variance = 95.07%
Dataset akhir	14.60 baris x 68 kolom, missing = 0, duplikat = 0

Dataset hasil cleaning terdiri dari 1.460 baris dan 76 kolom dengan seluruh missing value telah ditangani serta outlier pada atribut numerik terpilih telah disesuaikan menggunakan IQR capping.

Tahap transformasi dan reduksi dimensi selanjutnya menghasilkan 66 principal component yang mampu mempertahankan sekitar 95,07% variasi informasi data.