

Laporan Hasil Analisis Tugas Scrapping dan EDA

1. Deskripsi Dataset

Dataset yang digunakan merupakan data postingan dari halaman Newest pada Hacker News yang diperoleh melalui proses web scraping. Proses scraping dilakukan menggunakan library Requests dan BeautifulSoup dengan mengikuti pagination pada halaman tersebut. Dataset mentah yang diperoleh terdiri dari 1.500 baris dan 6 atribut, yaitu title, domain, points, author, age, dan comments. Atribut title, domain, dan author merupakan atribut nominal, sedangkan points dan comments merupakan atribut numerik diskrit. Atribut age menunjukkan waktu sejak postingan dibuat dan selanjutnya dikonversi menjadi age_minutes agar dapat dianalisis secara numerik.

2. Statistik Deskriptif

Atribut	Mean	Median	Modus	Std. Deviasi	Min	Max
Points	12,568	2	2	60,224	1	975
Comments	6,276	0	0	39,775	0	717
Age (menit)	926,092	960	2	422,824	1	1440

Hasil statistik deskriptif menunjukkan bahwa rata-rata points sebesar 12,568, sedangkan mediannya hanya 2. Perbedaan tersebut terjadi karena sebagian besar postingan memiliki points rendah, tetapi terdapat beberapa postingan dengan points sangat tinggi hingga 975. Atribut comments memiliki rata-rata 6,276 dengan median dan modus sebesar 0, sehingga sebagian besar postingan memiliki sedikit atau belum memiliki komentar. Sementara itu, age_minutes memiliki rata-rata 926,092 menit dengan median 960 menit dan nilai maksimum 1.440 menit.

3. Penanganan Data


Pemeriksaan kualitas data menemukan 54 missing value pada atribut domain, sedangkan atribut lainnya tidak memiliki nilai yang hilang. Missing value tersebut berasal dari postingan yang tidak mencantumkan domain eksternal, seperti beberapa postingan internal Hacker News. Data tersebut tidak dihapus karena atribut lainnya masih memiliki informasi yang dapat digunakan. Nilai domain yang kosong kemudian diisi dengan kategori Internal/No Domain, sehingga seluruh 1.500 data tetap dipertahankan.

Deteksi outlier menggunakan metode Interquartile Range (IQR) menemukan 167 outlier pada points dengan batas atas 8,5 dan 168 outlier pada comments dengan batas atas 2,5. Outlier tidak dihapus karena nilai points dan comments yang tinggi masih dapat menggambarkan tingkat interaksi yang nyata pada suatu postingan. Selain itu, atribut age

yang awalnya berbentuk teks ditransformasikan menjadi `age_minutes` agar waktu postingan dapat dianalisis dalam bentuk numerik.

4. Visualisasi & Interpretasi

Visualisasi distribusi points menunjukkan bahwa sebagian besar postingan memiliki jumlah points yang rendah. Data terkumpul pada sisi kiri histogram, sedangkan hanya sedikit postingan yang memperoleh points sangat tinggi. Pada distribusi domain, kategori Internal/No Domain memiliki jumlah terbanyak sebanyak 54 postingan. Untuk domain eksternal, youtube.com paling sering muncul dengan 34 postingan, diikuti arxiv.org sebanyak 21 postingan.



Hubungan antara points dan comments menunjukkan kecenderungan positif, yaitu postingan dengan points lebih tinggi cenderung memperoleh lebih banyak komentar. Hasil tersebut diperkuat oleh nilai korelasi sebesar 0,92, yang menunjukkan hubungan positif yang sangat kuat antara kedua atribut. Sementara itu, `age_minutes` memiliki korelasi yang sangat lemah terhadap points sebesar 0,05 dan terhadap comments sebesar 0,04.