ANALISIS POLA PEMBELIAN PELANGGAN MENGGUNAKAN ALGORITMA PREFIXSPAN PADA DATASET ONLINE RETAIL

Dinnetza Araafya Yudetti – 5054251018

1. Pendahuluan

Sequential Pattern Analysis merupakan salah satu teknik data mining yang digunakan untuk menemukan pola kejadian berdasarkan urutan waktu. Dalam transaksi ritel, metode ini dapat digunakan untuk mengetahui kecenderungan pelanggan membeli produk tertentu secara bersamaan maupun pada transaksi yang berbeda. Pola tersebut dapat memberikan informasi mengenai kebiasaan pembelian pelanggan yang tidak dapat diketahui hanya melalui frekuensi penjualan suatu produk.

Pada praktikum ini, analisis dilakukan menggunakan algoritma PrefixSpan (*Prefix-Projected Sequential Pattern Mining*) terhadap dataset Online Retail. Algoritma tersebut digunakan untuk menemukan pola pembelian berdasarkan riwayat transaksi setiap pelanggan. Pola yang diperoleh kemudian dievaluasi menggunakan nilai support dan confidence untuk mengetahui tingkat kemunculan serta kekuatan hubungan antartransaksi. Hasil analisis diharapkan dapat memberikan gambaran mengenai perilaku pembelian pelanggan dan menjadi pertimbangan dalam penyusunan strategi penjualan.

2. Eksplorasi dan Pembersihan Data

2.1 Eksplorasi Dataset

Dataset yang digunakan adalah Online Retail dari UCI Machine Learning Repository yang memuat transaksi penjualan sebuah toko ritel online di Inggris selama periode Desember 2010 hingga Desember 2011. Dataset tersebut terdiri atas 541.909 baris dan 8 kolom, yaitu InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, dan Country. Eksplorasi awal dilakukan menggunakan fungsi head(), shape, dan info() untuk mengetahui struktur, jumlah data, serta tipe data pada setiap kolom.

Dalam Sequential Pattern Analysis, kolom yang paling berperan adalah CustomerID, InvoiceNo, InvoiceDate, dan Description. CustomerID digunakan untuk mengidentifikasi pelanggan, InvoiceNo menunjukkan kelompok produk dalam satu transaksi, sedangkan InvoiceDate menentukan urutan pembelian. Kolom Description digunakan untuk mengetahui produk yang dibeli dan menyusun pola transaksi. Hasil eksplorasi juga menunjukkan adanya data kosong dan transaksi pembatalan sehingga diperlukan tahap pembersihan sebelum analisis dilakukan.

2.2 Pembersihan Data

Pembersihan data dilakukan dengan menghapus baris yang memiliki Description dan CustomerID kosong, transaksi pembatalan dengan InvoiceNo berawalan huruf C, serta transaksi dengan Quantity kurang dari atau sama dengan nol. Data yang tidak memenuhi ketentuan tersebut

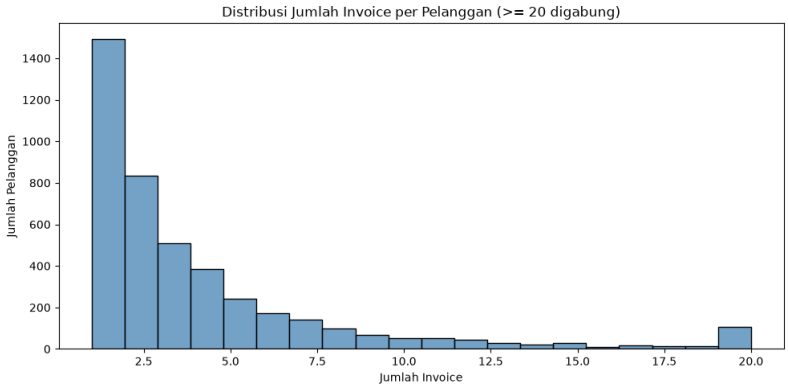
dikeluarkan karena dapat mengganggu pembentukan sequence pembelian pelanggan. Selanjutnya, nilai CustomerID diubah menjadi bilangan bulat dan penulisan Description dirapikan untuk menjaga konsistensi identitas produk.

Keterangan	Sebelum	Sesudah	Terhapus
Jumlah baris	541.909	397.924	143.985
Jumlah invoice	25.900	18.536	7.364
Jumlah pelanggan	4.372	4.339	33

Jumlah baris berkurang dari 541.909 menjadi 397.924 setelah proses pembersihan. Sebanyak 143.985 baris dihapus karena tidak memenuhi kriteria yang telah ditetapkan. Jumlah invoice juga berkurang menjadi 18.536, sedangkan pelanggan yang masih memiliki transaksi valid berjumlah 4.339. Dataset hasil pembersihan memiliki 3.866 jenis produk unik yang selanjutnya digunakan dalam proses Sequential Pattern Mining.

2.3 Distribusi Transaksi Pelanggan

Analisis distribusi transaksi dilakukan untuk mengetahui jumlah invoice yang dimiliki setiap pelanggan. Berdasarkan hasil pengolahan, rata-rata pelanggan melakukan 4,27 transaksi, dengan median sebanyak 2 transaksi. Terdapat 1.494 pelanggan yang hanya memiliki satu invoice dan 2.845 pelanggan yang memiliki setidaknya dua invoice. Jumlah transaksi terbanyak yang tercatat pada satu pelanggan mencapai 210 invoice.



Gambar 1. Distribusi Jumlah Invoice per Pelanggan

Distribusi tersebut menunjukkan bahwa sebagian pelanggan hanya melakukan pembelian dalam jumlah transaksi yang sedikit, sedangkan beberapa pelanggan melakukan pembelian berulang dengan frekuensi lebih tinggi. Pelanggan dengan beberapa invoice memberikan informasi yang lebih banyak untuk menemukan pola pembelian antarwaktu. Sementara itu, pelanggan dengan satu invoice tetap dapat digunakan untuk mengidentifikasi produk yang dibeli bersamaan dalam satu transaksi.

3. Persiapan Data Sequential Pattern Mining

Data yang telah dibersihkan kemudian disusun berdasarkan CustomerID dan InvoiceDate untuk membentuk urutan transaksi setiap pelanggan. Produk dengan InvoiceNo yang sama dikelompokkan menjadi satu itemset, sedangkan seluruh itemset milik pelanggan yang sama disusun menjadi sebuah sequence. Setiap produk yang muncul berulang dalam satu invoice hanya dicatat satu kali agar tidak terjadi duplikasi item dalam itemset.

Hasil pengolahan menghasilkan 18.536 itemset dari 4.339 pelanggan. Setiap pelanggan direpresentasikan oleh satu sequence yang berisi daftar itemset sesuai urutan transaksi. Bentuk sequence tersebut memungkinkan algoritma membedakan produk yang dibeli dalam satu invoice dengan produk yang dibeli pada invoice berbeda. Berdasarkan hasil pengecekan, terdapat 244 itemset dengan kombinasi CustomerID dan waktu transaksi yang sama, tetapi seluruh invoice tetap dipertahankan sebagai transaksi terpisah.

Panjang sequence dihitung berdasarkan jumlah invoice yang dimiliki setiap pelanggan. Hasilnya menunjukkan rata-rata panjang sequence sebesar 4,27 itemset, dengan panjang minimum 1 itemset dan maksimum 210 itemset. Data sequence ini kemudian digunakan sebagai masukan algoritma PrefixSpan untuk menemukan pola pembelian yang memenuhi batas minimum support.

4. Penerapan Algoritma PrefixSpan

4.1 Implementasi Algoritma

Algoritma PrefixSpan diterapkan untuk menemukan kombinasi produk yang sering muncul dalam urutan transaksi pelanggan. Proses pencarian dilakukan menggunakan pendekatan prefix dan projected database, yaitu dengan mengembangkan pola berdasarkan transaksi yang memenuhi prefix sebelumnya. Implementasi algoritma mendukung dua jenis pengembangan pola, yaitu I-extension untuk menambahkan produk dalam itemset yang sama dan S-extension untuk menambahkan itemset pada transaksi berikutnya dalam urutan waktu.

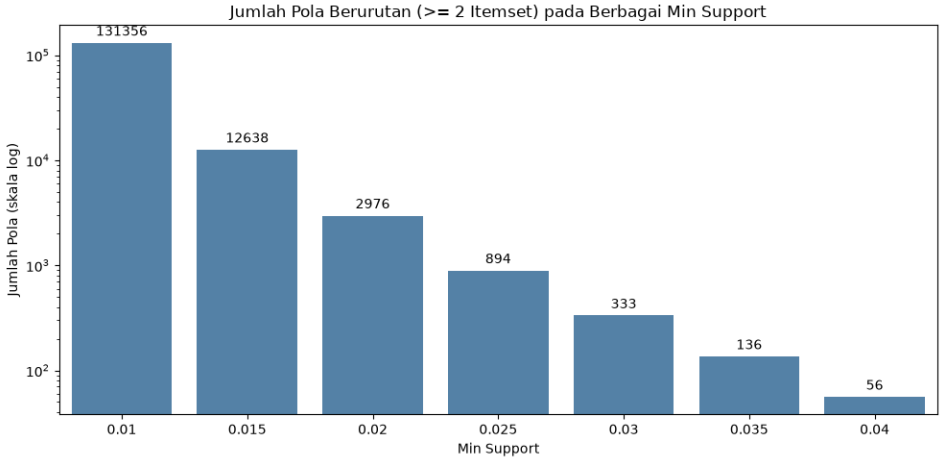
Dengan kedua pendekatan tersebut, algoritma dapat mengidentifikasi pembelian bersamaan maupun pembelian berurutan. Pembelian bersamaan menunjukkan produk yang muncul dalam satu invoice, sedangkan pembelian berurutan menunjukkan produk yang dibeli pada invoice yang lebih baru oleh pelanggan yang sama. Setiap pola dihitung berdasarkan jumlah pelanggan yang memenuhi pola tersebut sehingga pembelian berulang oleh satu pelanggan tidak menyebabkan penghitungan support secara berlebihan.

4.2 Penentuan Minimum Support

Nilai minimum support awal ditetapkan sebesar 0,01 atau 1% dari jumlah pelanggan sesuai ketentuan praktikum. Dengan jumlah 4.339 pelanggan, pola harus ditemukan pada sedikitnya 44 pelanggan agar memenuhi batas tersebut. Hasil penerapan PrefixSpan pada minimum support 1% menghasilkan 142.353 pola, yang terdiri atas 1.763 pola satu produk, 9.234 pola pembelian bersamaan, dan 131.356 pola pembelian berurutan.

Jumlah pola yang cukup besar menyebabkan hasil analisis menjadi sulit untuk difokuskan. Oleh karena itu, dilakukan perbandingan beberapa nilai minimum support untuk menentukan batas yang menghasilkan jumlah pola lebih mudah dianalisis.

Minimum Support	Total Pola	Pembelian Berurutan
1%	142.353	131.356
1,5%	16.700	12.638
2%	5.176	2.976
2,5%	2.233	894
3%	1.259	333
3,5%	822	136
4%	567	56

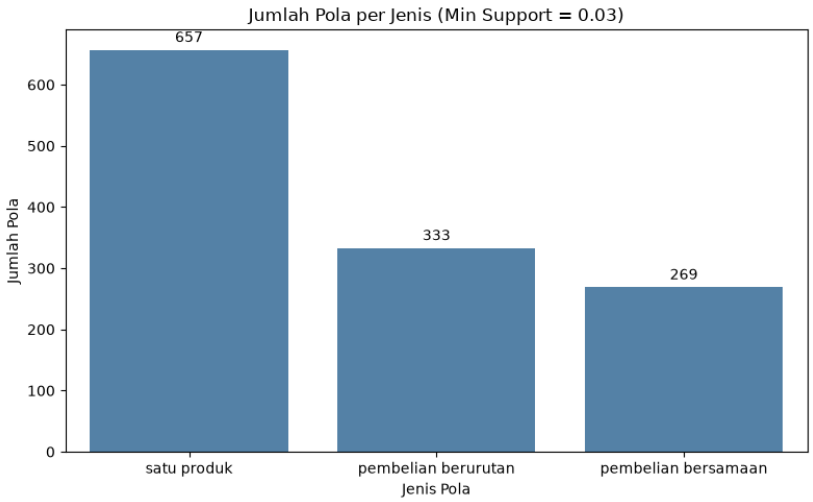


Gambar 3. Jumlah Pola Berurutan pada Berbagai Nilai Minimum Support

Peningkatan minimum support menyebabkan jumlah pola yang ditemukan semakin berkurang. Perubahan paling besar terlihat ketika minimum support dinaikkan dari 1% menjadi 1,5%, yaitu dari 142.353 menjadi 16.700 pola. Pada minimum support 3%, diperoleh 1.259 pola yang masih mencakup pembelian bersamaan dan pembelian berurutan. Nilai 3% kemudian dipilih untuk analisis akhir karena menghasilkan jumlah pola yang lebih terfokus tanpa menghilangkan seluruh variasi pola pembelian.

4.3 Hasil Penerapan PrefixSpan

Penerapan minimum support akhir sebesar 3% menghasilkan 1.259 pola dengan batas kemunculan minimum pada 131 pelanggan. Pola yang ditemukan terdiri atas 657 pola satu produk, 269 pola pembelian bersamaan, dan 333 pola pembelian berurutan. Sebagian besar pola hanya memiliki satu itemset, sedangkan pola terpanjang yang ditemukan terdiri atas empat itemset.



Gambar 4. Jumlah Pola Berdasarkan Jenis

Pola satu produk memiliki jumlah paling banyak dibandingkan jenis pola lainnya. Hal ini menunjukkan bahwa terdapat banyak produk yang memenuhi batas minimum support secara individual. Sementara itu, ditemukannya 333 pola berurutan memperlihatkan adanya keterkaitan pembelian antar-invoice pada sejumlah pelanggan. Sebanyak 42 pola berurutan juga memuat itemset dengan lebih dari satu produk, sehingga hasil algoritma tidak hanya terbatas pada pembelian satu produk dalam setiap transaksi.

Validasi dilakukan dengan membandingkan nilai support hasil PrefixSpan terhadap perhitungan langsung pada seluruh 1.259 pola. Hasil pemeriksaan menunjukkan bahwa nilai support seluruh pola sesuai dengan perhitungan langsung. Selain itu, hasil penyaringan pola pada minimum support 3% juga sama dengan hasil penerapan ulang PrefixSpan menggunakan batas tersebut. Hasil ini menunjukkan bahwa proses pencarian dan penghitungan support pada implementasi algoritma telah berjalan secara konsisten.

5. Evaluasi Pola Berurutan

5.1 Evaluasi Support dan Confidence

Evaluasi dilakukan menggunakan metrik support dan confidence untuk mengetahui frekuensi kemunculan serta kekuatan hubungan pada pola pembelian. Support menunjukkan proporsi pelanggan yang memiliki suatu pola dibandingkan seluruh pelanggan dalam dataset. Sementara itu, confidence pada pola berurutan menunjukkan proporsi pelanggan yang memiliki pola lengkap di antara pelanggan yang memenuhi prefix pola tersebut.

Nilai support yang tinggi menunjukkan bahwa pola ditemukan pada lebih banyak pelanggan, sedangkan confidence yang tinggi menunjukkan hubungan yang lebih kuat antara prefix dan kelanjutan pola. Pada implementasi ini, confidence dihitung untuk pola yang memiliki minimal dua itemset. Oleh karena itu, pola satu itemset tidak memiliki nilai confidence karena tidak memiliki prefix transaksi sebelumnya yang digunakan sebagai dasar perhitungan.

Berdasarkan hasil evaluasi, sebanyak 333 pola pembelian berurutan memiliki rata-rata support sebesar 0,0361 dan rata-rata confidence sebesar 0,3478. Nilai support tertinggi mencapai 0,0933, sedangkan confidence tertinggi mencapai 0,6700. Hasil tersebut menunjukkan bahwa pola dengan frekuensi kemunculan tertinggi tidak selalu memiliki confidence tertinggi, sehingga kedua metrik perlu dipertimbangkan secara bersamaan.

5.2 Tiga Pola dengan Support Tertinggi

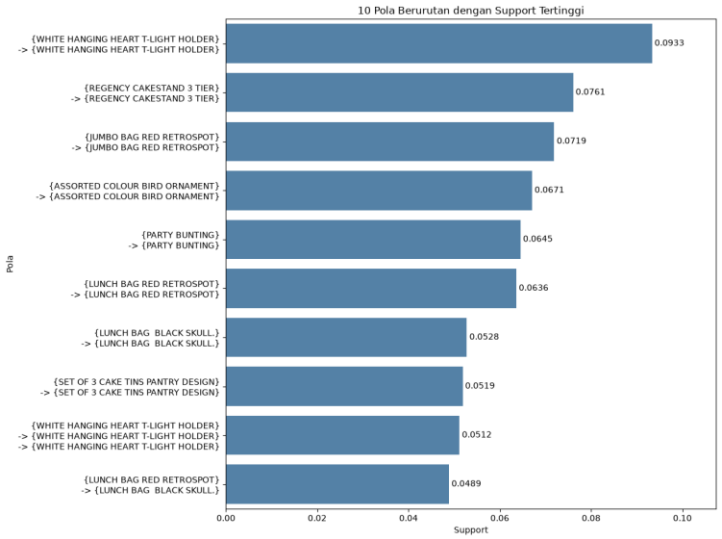
Produk	Jumlah Pelanggan	Support
REGENCY CAKESTAND 3 TIER	881	20,30%
WHITE HANGING HEART T-LIGHT HOLDER	856	19,73%
PARTY BUNTING	708	16,32%

Pola pertama menunjukkan bahwa REGENCY CAKESTAND 3 TIER dibeli oleh 881 pelanggan atau 20,30% dari seluruh pelanggan. Produk WHITE HANGING HEART T-LIGHT HOLDER menempati posisi kedua dengan 856 pelanggan atau 19,73%, sedangkan PARTY BUNTING berada pada posisi ketiga dengan 708 pelanggan atau 16,32%. Ketiga produk tersebut memiliki jangkauan pembelian yang relatif tinggi dan dapat menjadi pertimbangan dalam pengelolaan persediaan.

Meskipun memiliki support tertinggi, ketiga pola tersebut merupakan pola satu produk sehingga belum menunjukkan hubungan pembelian antarwaktu. Oleh karena itu, analisis dilanjutkan dengan memilih pola yang terdiri atas minimal dua itemset untuk mengetahui kecenderungan pembelian berurutan.

5.3 Analisis Pola Pembelian Berurutan

Hasil PrefixSpan menunjukkan bahwa pola pembelian berurutan dengan support tertinggi didominasi oleh pembelian ulang produk yang sama.



Gambar 5. Sepuluh Pola Pembelian Berurutan dengan Support Tertinggi

Pola pertama menunjukkan bahwa 405 pelanggan membeli WHITE HANGING HEART T-LIGHT HOLDER pada setidaknya dua invoice berbeda. Nilai confidence sebesar 47,31% menunjukkan bahwa hampir setengah pelanggan yang pernah membeli produk tersebut juga tercatat membelinya kembali pada transaksi yang lebih baru. Hal ini menunjukkan adanya kecenderungan pembelian berulang yang cukup kuat pada produk tersebut. Artinya, pelanggan yang pernah membeli produk ini memiliki kecenderungan pembelian ulang yang relatif lebih besar dibandingkan dua produk lainnya berdasarkan hasil pengamatan dataset. Temuan tersebut dapat dimanfaatkan sebagai dasar penyusunan promosi pembelian ulang atau rekomendasi produk kepada pelanggan.

5.4 Analisis Pola Pembelian Produk Berbeda

Selain pembelian ulang, hasil algoritma juga menunjukkan pola pembelian berurutan yang melibatkan produk berbeda. Dari 333 pola pembelian berurutan, terdapat 267 pola yang melibatkan lebih dari satu jenis produk dan 66 pola berupa pembelian ulang produk yang sama.

Pola Pembelian	Support	Confidence
LUNCH BAG RED RETROSPOT → LUNCH BAG BLACK SKULL	4,89%	39,85%
LUNCH BAG CARS BLUE → LUNCH BAG RED RETROSPOT	4,82%	43,63%
LUNCH BAG BLACK SKULL. → LUNCH BAG RED RETROSPOT	4,79%	45,41%

Pola dengan support tertinggi menunjukkan bahwa pelanggan yang membeli LUNCH BAG RED RETROSPOT kemudian membeli LUNCH BAG BLACK SKULL. pada transaksi yang lebih baru. Pola tersebut ditemukan pada 4,89% pelanggan dengan confidence sebesar 39,85%. Sementara itu, pola LUNCH BAG BLACK SKULL. yang diikuti LUNCH BAG RED RETROSPOT memiliki confidence sebesar 45,41%, menunjukkan hubungan yang relatif lebih kuat berdasarkan proporsi pelanggan yang memenuhi prefix-nya.

Ketiga pola tersebut memperlihatkan keterkaitan pembelian antarproduk dalam kategori lunch bag. Hasil ini dapat menjadi pertimbangan untuk memberikan rekomendasi produk dengan desain berbeda kepada pelanggan yang sebelumnya membeli produk sejenis. Namun, pola yang ditemukan menunjukkan hubungan berdasarkan riwayat transaksi dan tidak secara langsung membuktikan bahwa pembelian produk pertama menyebabkan pembelian produk berikutnya.

5.5 Analisis Pembelian Bersamaan

Selain pola pembelian berurutan, PrefixSpan juga menghasilkan pola produk yang dibeli dalam invoice yang sama. Pola pembelian bersamaan dengan support tertinggi adalah PAPER CHAIN KIT 50'S CHRISTMAS dan PAPER CHAIN KIT VINTAGE CHRISTMAS, yang ditemukan pada 313 pelanggan dengan support sebesar 7,21%. Pola berikutnya adalah GREEN REGENCY

TEACUP AND SAUCER dan ROSES REGENCY TEACUP AND SAUCER dengan support sebesar 7,17%.

Hasil tersebut menunjukkan bahwa beberapa produk yang memiliki fungsi atau karakteristik serupa cenderung dibeli dalam satu transaksi. Informasi ini dapat dimanfaatkan sebagai pertimbangan penempatan produk, penyusunan paket penjualan, maupun promosi produk yang saling berkaitan. Pola pembelian bersamaan juga melengkapi hasil pembelian berurutan karena memberikan informasi mengenai hubungan antarproduk dalam satu invoice, bukan hanya antarwaktu transaksi.

6. Kesimpulan

Berdasarkan hasil praktikum Sequential Pattern Analysis menggunakan algoritma PrefixSpan, diperoleh beberapa kesimpulan sebagai berikut.

1. Proses pembersihan dataset Online Retail menghasilkan 397.924 baris transaksi valid, 18.536 invoice, dan 4.339 pelanggan. Data tersebut berhasil disusun menjadi sequence pembelian berdasarkan pelanggan dan urutan waktu transaksi.
2. Penerapan algoritma PrefixSpan dengan minimum support awal 1% menghasilkan 142.353 pola. Setelah dilakukan evaluasi, minimum support ditetapkan sebesar 3% sehingga diperoleh 1.259 pola yang terdiri atas 657 pola satu produk, 269 pola pembelian bersamaan, dan 333 pola pembelian berurutan.
3. Pola pembelian berurutan dengan support tertinggi menunjukkan kecenderungan pembelian ulang produk WHITE HANGING HEART T-LIGHT HOLDER, REGENCY CAKESTAND 3 TIER, dan JUMBO BAG RED RETROSPOT. Hasil evaluasi support dan confidence menunjukkan adanya perbedaan antara frekuensi kemunculan pola dan kekuatan hubungan pembelian.
4. Pola pembelian produk berbeda menunjukkan keterkaitan antarproduk dalam kategori lunch bag, sedangkan pola pembelian bersamaan menunjukkan kecenderungan beberapa produk dibeli dalam satu invoice. Temuan ini dapat dimanfaatkan sebagai pertimbangan dalam pengelolaan persediaan, rekomendasi produk, dan strategi promosi berdasarkan riwayat pembelian pelanggan.